

DuocUC



INGENIERIA DE SOLUCIONES CON INTELIGENCIA ARTIFICIAL

ISY0101-003D
Sede Alameda

Evaluación N°3

Tomas caceres
Martina Flores

GIOCRISRAI GODOY BONILLO

ÍNDICE DE CONTENIDO

INGENIERIA DE SOLUCIONES CON INTELIGENCIA ARTIFICIAL.....	1
Introducción.....	3
1. Implementación de Métricas de Observabilidad.....	3
1.1 Métricas de Calidad (Precisión, Fidelidad y Consistencia).....	3
1.2 Métricas de Rendimiento y Errores (Latencia).....	3
2. Análisis de Registros y Trazabilidad.....	4
2.1 Trazabilidad del Flujo de Ejecución.....	4
2.2 Identificación de Anomalías y Fallas.....	4
3. Desarrollo de Dashboard y Visualización.....	4
4. Integración de Protocolos de Seguridad y Uso Responsable.....	5
5. Propuesta de Optimización y Conclusiones.....	5
2.1 Recomendaciones Prácticas.....	5

Introducción

El presente informe detalla la implementación de un sistema de observabilidad y trazabilidad sobre el Agente PetAsesor, un pipeline de Agente de Lenguaje Extenso (LLM) con Recuperación Aumentada de Generación (RAG) diseñado para la cadena de tiendas PetCo. El objetivo principal es evaluar y monitorear el desempeño del agente en escenarios de producción, aplicando métricas clave como la latencia, la fidelidad, la precisión de contexto y la tasa de error. Mediante el análisis de los registros de ejecución, se han identificado puntos críticos y se proponen mejoras fundamentadas para aumentar la sostenibilidad y escalabilidad de la solución.

1. Implementación de Métricas de Observabilidad

Para medir el rendimiento del agente en escenarios con variabilidad de datos, se aplicaron un conjunto de métricas de observabilidad clasificadas en tres pilares: Calidad de Respuesta, Rendimiento y Uso de Recursos, tal como se requiere en las instrucciones. La implementación se centraliza en la función `compute_observability_metrics` dentro del código fuente.

1.1 Métricas de Calidad (Precisión, Fidelidad y Consistencia)

Las métricas de calidad buscan cuantificar la utilidad y la fiabilidad de las respuestas del agente, cumpliendo con el requisito de medir la precisión y consistencia.

Fidelidad Media (`faithfulness_mean`) y Relevancia Media (`relevance_mean`): Se evalúan mediante llamadas al modelo de chat (LLM como evaluador) a nivel de log de interacción, comparando la respuesta con la consulta y el contexto recuperado. Esto asegura que la respuesta esté directamente sustentada por la Base de Conocimiento de PetCo y que sea pertinente a la pregunta del usuario.

Precisión de Contexto Media (`precision_media`): Mide la calidad del módulo RAG, calculando el porcentaje promedio de documentos recuperados que son efectivamente relevantes para la consulta.

Consistencia (`consistency`): Se calcula como un indicador de la variabilidad del sistema. En el código, se obtiene a partir del Coeficiente de Variación (CV) de la latencia total, donde un valor más cercano a 1.0 indica un comportamiento más predecible y consistente.

1.2 Métricas de Rendimiento y Errores (Latencia)

El rendimiento se mide primariamente a través del tiempo de respuesta (latencia) y la estabilidad operativa.

Latencia (`latency`): La función rastrea el `total_time` de cada interacción, discriminando entre el tiempo de recuperación (`retrieval_time`) y el tiempo de generación (`generation_time`). Se reportan estadísticas agregadas como la media, la mediana y la desviación estándar para un análisis completo de la distribución del tiempo de respuesta.

Tasa de Error (`error_rate`): Esta métrica monitorea la frecuencia de fallas operacionales, definidas como interacciones que resultan en una respuesta que comienza con "Error" o que registran un tiempo total de cero (falla no capturada).

2. Análisis de Registros y Trazabilidad

El análisis de registros es fundamental para identificar con precisión los cuellos de botella y los puntos de falla en el flujo automatizado del Agente PetAsesor.

2.1 Trazabilidad del Flujo de Ejecución

El agente está configurado con el framework LangChain bajo la arquitectura ReAct, el cual permite la trazabilidad completa del razonamiento. La activación del modo `verbose=True` y la captura de `intermediate_steps` permiten examinar el proceso de planificación: `Thought` (qué está pensando el Agente), `Action` (qué herramienta usará), y `Observation` (el resultado de la herramienta). Esta trazabilidad es esencial para verificar si el agente está decidiendo correctamente cuándo usar la herramienta `petco_data_lookup` (RAG) o si está respondiendo directamente desde su memoria conversacional. El uso de la memoria conversacional (`ConversationBufferWindowMemory`) también se rastrea, asegurando el cumplimiento de la trazabilidad en cada ejecución.

2.2 Identificación de Anomalías y Fallas

La función `analyze_logs_for_failures` realiza un examen automatizado de los logs para detectar tres tipos de incidentes, permitiendo la identificación de patrones y anomalías:

1. Alta Latencia (`high_latency`): Registra cualquier interacción cuyo tiempo total exceda un umbral predefinido (e.g., 2.0 segundos).
2. Baja Fidelidad (`low_faithfulness`): Marca las interacciones donde el puntaje de fidelidad está por debajo de un límite crítico (e.g., 2.5), indicando respuestas potencialmente alucinatorias o sin soporte contextual.
3. Respuesta de Error (`error_response`): Captura fallas explícitas del modelo o del sistema RAG.
- 4.

Este análisis genera una lista de incidentes y un resumen de las recomendaciones de alto nivel, sirviendo como el insumo directo para el reporte de optimización.

3. Desarrollo de Dashboard y Visualización

Para la visualización del desempeño, se construyó un dashboard dentro de la misma aplicación utilizando Streamlit y Plotly.express, cumpliendo con la flexibilidad de usar una herramienta de monitoreo.

El dashboard presenta las métricas clave de forma interactiva:

- **Histograma de Fidelidad:** Muestra la distribución de los puntajes de faithfulness, permitiendo identificar rápidamente si la mayoría de las respuestas se concentran en rangos aceptables (4-5) o críticos (1-3).
- **Gráfico de Dispersión (Precisión vs. Fidelidad):** Permite analizar la correlación entre la calidad del contexto recuperado (context_precision) y la calidad de la respuesta generada (faithfulness). Un hallazgo común es que la baja precisión de contexto a menudo se correlaciona con baja fidelidad.

Además, el dashboard facilita la exportación de los logs en formatos CSV y JSON (LangSmith), permitiendo su integración con sistemas de monitoreo externos o la creación de conjuntos de datos para entrenamiento y re-evaluación.

4. Integración de Protocolos de Seguridad y Uso Responsable

En el diseño del Agente PetAsesor se integraron protocolos de uso responsable directamente en la instrucción del modelo. El prompt del sistema establece el rol y los límites del agente:

- **Persona Definida:** Se define al agente como "'PetAsesor', un asistente virtual de PetCo".
- **Limitación de Contexto (Fidelidad):** La instrucción "Responde las preguntas basándote únicamente en la información del contexto. No inventes información" opera como una salvaguarda contra la alucinación, que es un riesgo de seguridad en sistemas RAG.
- **Advertencia Ética:** El prompt incluye una instrucción de derivación de responsabilidad: "Si la información no es suficiente, debes informar al usuario que contacte con un experto de la tienda o un veterinario." Esto evita que el agente brinde consejos médicos sin la debida calificación o contexto completo, asegurando un uso ético y responsable en un contexto de salud y bienestar animal.

5. Propuesta de Optimización y Conclusiones

El análisis de datos observados (latencia, fidelidad y errores) proporciona una base sólida para proponer mejoras orientadas a la sostenibilidad y escalabilidad.

5.1 Recomendaciones Prácticas

Las recomendaciones se derivan directamente de los incidentes reportados por *analyze_logs_for_failures*:

1. Optimizar la Recuperación y Cacheo de Embeddings: Si la Latencia Media es alta, se justifica la implementación de un mecanismo de caching para los embeddings generados o la exploración de índices vectoriales más eficientes, reduciendo así el *retrieval_time*.
2. Mejorar la Base de Conocimiento (KB): Una baja Fidelidad Media o alta tasa de incidentes por *low_faithfulness* sugiere una necesidad de limpieza y segmentación de la KB. Se recomienda revisar y mejorar la calidad de los documentos de origen, asegurando que el contexto sea conciso y libre de ambigüedades.
3. Implementar Control de Excepciones y Reintentos: La Tasa de Error puede disminuir significativamente con la implementación de control de excepciones (ej. *try-except* más robustos) y políticas de reintento en las llamadas a la API de generación.

5.2 Sostenibilidad y Escalabilidad

Las mejoras propuestas impactan directamente en la sostenibilidad y escalabilidad del Agente PetAsesor. La optimización de la latencia y la reducción de la tasa de error disminuyen el costo operativo por interacción y mejoran la experiencia del usuario (QoS). Un agente más rápido y más preciso es más eficiente en términos de recursos computacionales, lo cual es fundamental para el escalamiento a un mayor volumen de usuarios sin comprometer la calidad del servicio.